

Sistema Híbrido Baseado em *Encoders* e Difusores para Aumento de Dados em Imagens de Histologia do Câncer de Mama

1 INTRODUÇÃO

O câncer de mama é o tipo de neoplasia maligna mais frequentemente diagnosticado entre mulheres em todo o mundo. Segundo levantamento da Organização Mundial da Saúde, são registrados mais de 2,3 milhões de novos casos por ano, e a doença é responsável pela segunda principal causa de morte por câncer em mulheres em quase 95% dos países (ALZAHIRANI; RAZA; ASGHAR, 2025). No Brasil, o Instituto Nacional de Câncer (INCA) estima dezenas de milhares de novos casos anuais, tornando o diagnóstico precoce e preciso uma prioridade de saúde pública. Nesse contexto, a histologia, análise microscópica de tecidos corados, geralmente pela técnica de hematoxilina e eosina (H&E), representa o padrão para a confirmação diagnóstica do câncer de mama (MBOUOBDA; DJAGBA, 2025).

A patologia digital, impulsionada pelo surgimento de scanners de imagens de lâmina inteira (*Whole Slide Images*, WSI), tem possibilitado a digitalização em larga escala de amostras histopatológicas, abrindo caminho para a aplicação de técnicas computacionais no auxílio ao diagnóstico. Algoritmos de aprendizado profundo (*Deep Learning*), especialmente as redes neurais convolucionais (*Convolutional Neural Networks*, CNNs), têm demonstrado desempenho comparável ao de especialistas humanos em diversas tarefas de classificação de imagens médicas (RAHMAN et al., 2025). Modelos baseados em CNNs, Transformers e arquiteturas híbridas já alcançaram acurácias superiores a 99% em bases de dados públicas como BreakHis e BACH (ZHOU et al., 2025).

Entretanto, a efetividade desses modelos depende criticamente da disponibilidade de grandes volumes de dados rotulados para treinamento. A obtenção de imagens histopatológicas anotadas por especialistas é um processo custoso, demorado e sujeito a restrições éticas e legais de privacidade, o que resulta em conjuntos de dados frequentemente pequenos e desbalanceados entre as classes (GUERRERO et al., 2024). O desbalanceamento de classes é um problema especialmente relevante na histologia do câncer de mama, pois os subtipos malignos podem ser bem menos representados do que os tecidos normais ou benignos, comprometendo a capacidade de generalização dos modelos de classificação.

Técnicas tradicionais de aumento de dados como rotações, espelhamentos, ajustes de brilho e cortes são amplamente empregadas, mas sua capacidade de representar a

variabilidade fenotípica real dos tecidos tumorais é limitada, pois derivam transformações das amostras originais sem introduzir genuína diversidade biológica. Métodos generativos mais sofisticados, em especial as redes adversárias generativas, foram propostos para gerar amostras sintéticas com maior grau de realismo (MAN; YANG; XU, 2020). Contudo, o treinamento de redes adversariais generativas (*Generative Adversarial Networks*, GANs) é notoriamente instável, propenso a problemas como *mode collapse* e dificuldade de convergência, especialmente com conjuntos de dados pequenos.

Modelos de difusão (*Diffusion Models*) emergem como uma alternativa promissora, demonstrando superioridade na geração de imagens de alta qualidade e estabilidade de treinamento em relação às GANs em diversas tarefas de síntese. Os modelos de difusão latente (*Latent Diffusion Models*, LDMs) aplicam o processo de difusão no espaço latente comprimido de um *autoencoder*, reduzindo drasticamente o custo computacional sem perda significativa de qualidade visual (ROMBACH *et al.*, 2022). Modelos de difusão probabilística conseguem sintetizar imagens médicas de alta qualidade em modalidades como Ressonância Magnética (RM) e Tomografia Computadorizada (TC), com uso potencial para aumento de dados em cenários de escassez (KHADER *et al.*, 2023). Evidências demonstram ainda que modelos de difusão superam abordagens baseadas em GANs na geração de imagens médicas sintéticas segmentadas, com melhor transferibilidade para outros conjuntos de dados (SARAGIH; HIBI; TYRRELL, 2023).

Nesse cenário, a proposta de sistemas híbridos que combinam as capacidades de representação de *autoencoders* com a qualidade generativa dos modelos de difusão abre uma perspectiva inovadora. Tal abordagem permite que o encoder mapeie as imagens histopatológicas para um espaço latente estruturado e semanticamente rico, enquanto o modelo de difusão opera nesse espaço comprimido para gerar amostras sintéticas diversificadas e realistas. A hipótese central deste trabalho é que um sistema híbrido Encoder-Difusor pode superar, em termos de qualidade das imagens geradas e de desempenho dos classificadores treinados com os dados aumentados, as técnicas generativas anteriores aplicadas ao domínio da histologia do câncer de mama.

Diante do exposto, o objetivo geral deste trabalho é desenvolver e avaliar um sistema híbrido baseado em arquitetura Encoder-Difusor para aumento de dados em imagens de histologia e histologia do câncer de mama, visando à melhoria do desempenho de modelos de classificação automática. Como objetivos específicos, enumeram-se: (i) realizar levantamento

bibliográfico sistemático sobre técnicas de aumento de dados generativo aplicadas à histologia, com foco em modelos de difusão e arquiteturas híbridas; (ii) implementar e adaptar uma arquitetura de modelo de difusão latente baseada em encoder para o domínio de imagens histopatológicas de câncer de mama; (iii) gerar imagens sintéticas e avaliar sua qualidade por meio de métricas quantitativas como FID (*Fréchet Inception Distance*) e qualitativas por inspeção de especialistas; (iv) treinar classificadores com os dados aumentados e comparar o desempenho com o obtido por técnicas tradicionais de aumento e por GANs; e (v) analisar criticamente os resultados e discutir as limitações e perspectivas do método proposto.

A relevância desta pesquisa reside em dois aspectos centrais. Do ponto de vista clínico, sistemas de auxílio ao diagnóstico (*Computer-Aided Diagnosis*, CADx) mais precisos podem contribuir para diagnósticos mais precoces e acurados, com impacto direto na sobrevivência das pacientes. Do ponto de vista científico, a investigação de arquiteturas híbridas Encoder-Difusor em domínios médicos com dados escassos pode fornecer subsídios para avanços na área de geração de imagens sintéticas aplicadas à saúde.

Este trabalho está organizado da seguinte forma. No Capítulo 2 é apresentada a base conceitual necessária para a compreensão dos métodos utilizados, incluindo os fundamentos de histologia do câncer de mama, aprendizado profundo, aumento de dados generativos, modelos de difusão e arquiteturas híbridas Encoder-Difusor.

2 BASE CONCEITUAL

Neste capítulo são apresentados os principais conceitos necessários para a compreensão das técnicas e ferramentas utilizadas no desenvolvimento deste trabalho. O capítulo está organizado em quatro seções: (i) histologia do câncer de mama e o problema do diagnóstico computacional; (ii) fundamentos de aprendizado profundo aplicado a imagens médicas; (iii) aumento de dados generativo com modelos de difusão; e (iv) arquiteturas híbridas Encoder-Difusor para síntese de imagens.

2.1 Histologia do Câncer de Mama

O câncer de mama é uma doença heterogênea, caracterizada por diferentes subtipos moleculares e histológicos com comportamentos clínicos e prognósticos distintos. O diagnóstico definitivo é realizado por meio da análise histopatológica de amostras de tecido coradas com hematoxilina e eosina (H&E), nas quais um patologista avalia características

morfológicas como a disposição celular, o grau nuclear e a presença de mitoses. Entre os principais subtipos histológicos, destacam-se o carcinoma ductal invasivo (CDI), responsável por cerca de 70–80% dos casos, e o carcinoma lobular invasivo (CLI). Além das formas invasivas, existem lesões in situ, como o carcinoma ductal in situ (CDIS), que também exigem diagnóstico preciso para orientar a conduta terapêutica (BONACHO *et al.*, 2020).




Figura 1 – Imagem histológica da glândula tireoide, corada por hematoxilina – eosina.

A avaliação microscópica manual é, contudo, um processo laborioso, subjetivo e dependente da experiência do profissional. A variabilidade interobservadora é reconhecida na literatura como um fator de limitação diagnóstica, especialmente em lesões de bordas indistintas ou de grau intermediário. Com a digitalização das lâminas histológicas por scanners de alta resolução, gerou-se um volume massivo de imagens WSI frequentemente com bilhões de pixels por lâmina, o que criou tanto um desafio computacional quanto uma oportunidade ímpar para a aplicação de modelos de aprendizado de máquina. Revisões sistemáticas dos avanços recentes em modelos de aprendizado profundo para detecção do câncer de mama relatam que arquiteturas de CNN atingem acurácias superiores a 99% em mamografias em condições ideais de dados (RAHMAN *et al.*, 2025).

Bases de dados públicas como BreakHis (SPANHOL *et al.*, 2016), BACH (ARESTA *et al.*, 2019) e IDC (JANOWCZYK; MADABHUSHI, 2016) têm sido amplamente utilizadas para benchmarking de métodos computacionais na histologia do câncer de mama. A base BreakHis, por exemplo, contém 7.909 imagens de tecido mamário benigno e maligno em quatro fatores de ampliação microscópica (40×, 100×, 200×, 400×). Apesar da relevância dessas bases, todas apresentam limitações quanto ao número de amostras e ao desbalanceamento entre categorias, reforçando a necessidade de estratégias eficazes de aumento de dados.

2.2 Aprendizado Profundo para Classificação de Imagens Histopatológicas

O aprendizado profundo compreende um subconjunto do aprendizado de máquina (*Machine Learning*) no qual arquiteturas de redes neurais artificiais com múltiplas camadas ocultas aprendem representações hierárquicas dos dados de entrada. No contexto de imagens, as CNNs exploram a invariância translacional da convolução para extrair características locais bordas, texturas, padrões morfológicos de forma progressivamente mais abstrata ao longo das camadas (LECUN; BENGIO; HINTON, 2015). Arquiteturas como VGG (*Visual Geometry Group*), ResNet, DenseNet e EfficientNet consolidaram-se como referências em tarefas de classificação de imagens histopatológicas.

Mais recentemente, os Vision Transformers (ViTs) e suas variantes introduziram mecanismos de atenção global que superam as limitações do campo receptivo local das CNNs, capturando dependências de longa distância entre regiões da imagem. O ResViT-GANNet, uma arquitetura de duplo ramo que combina CNN com atenção por canal e ViT com fusão de tokens, atingiu acurácia de 96,40% na classificação de 4 classes na base BACH e 98,22% em múltiplos fatores de ampliação na BreakHis, superando significativamente métodos anteriores (ZHOU *et al.*, 2025). Um achado relevante desse trabalho é que a incorporação de dados sintéticos gerados por StyleGAN2-ADA resultou em melhoria média de 3,3% na acurácia, evidenciando o impacto do aumento generativo.

A avaliação dos modelos de classificação é realizada por meio de métricas como acurácia, precisão, revocação, F1-Score e AUC-ROC (*Area Under the Receiver Operating Characteristic Curve*). Em cenários de desbalanceamento de classes, a acurácia isolada pode ser enganosa, sendo o F1-Score e a AUC-ROC métricas mais informativas. Estratégias de aumento de dados combinadas com técnicas de balanceamento na função de perda melhoram a classificação de classes minoritárias em imagens histopatológicas densamente anotadas, sem comprometer o desempenho nas classes majoritárias (GUERRERO *et al.*, 2024).

2.3 Aumento de Dados Generativo: de GANs a Modelos de Difusão

O aumento de dados (*data augmentation*) é uma estratégia para ampliar artificialmente o conjunto de treinamento, reduzir o sobreajuste (*overfitting*) e melhorar a generalização dos modelos. Técnicas clássicas incluem transformações geométricas (rotação, espelhamento, zoom), ajustes fotométricos (brilho, contraste, saturação) e cortes aleatórios. Embora essas

abordagens sejam computacionalmente baratas, sua capacidade de introduzir variabilidade morfológica genuína em imagens histopatológicas é limitada.

As GANs consistem em dois componentes: um gerador, que aprende a produzir amostras sintéticas a partir de ruído aleatório, e um discriminador, que distingue amostras reais de sintéticas. O aprendizado adversarial resulta, idealmente, em imagens sintéticas indistinguíveis das reais. O DenseNet121-AnoGAN, proposto para classificação de imagens histopatológicas de mama, emprega detecção de anomalias por GAN para filtrar patches erroneamente rotulados, alcançando acurácia de 99,13% e F1-Score de 99,38% na base BreakHis (MAN; YANG; XU, 2020). Contudo, o treinamento de GANs é instável e propenso ao colapso de modo (*mode collapse*¹), em que o gerador passa a produzir amostras com baixa diversidade.

Os modelos de difusão probabilística (*Denoising Diffusion Probabilistic Models*, DDPMs) surgem como uma alternativa mais estável. Esses modelos aprendem a reverter progressivamente um processo de adição de ruído gaussiano a uma imagem, gerando amostras de alta qualidade a partir de ruído puro. Modelos de difusão conseguem gerar imagens médicas sintéticas com FID de até 0,85, indicando alta fidelidade em relação às imagens reais, e apresentam potencial como estratégia de aumento de dados de baixo custo para aplicações de inteligência artificial médica (CAO *et al.*, 2025). Modelos de difusão também superam GANs na geração de imagens médicas segmentadas, com resultados superiores de Dice score mesmo quando os classificadores são avaliados em conjuntos de dados distintos daqueles usados no treinamento (SARAGIH; HIBI; TYRRELL, 2023).

Pesquisadores aplicaram DDPMs à geração de volumes de RM e TC tridimensionais, com avaliação qualitativa por radiologistas quanto à aparência realista, correção anatômica e consistência entre fatias. Imagens sintéticas geradas por difusão melhoram o desempenho de modelos de segmentação de mama quando os dados reais são escassos, com aumento do Dice score de 0,91 para 0,95 após inclusão de dados sintéticos, evidenciando o impacto prático do aumento generativo (KHADER *et al.*, 2023).

¹ *Mode collapse* é quando o gerador de uma GAN aprende a produzir saídas repetitivas ou pouco diversas, mapeando diferentes entradas para saídas semelhantes. Na forma parcial, mais comum, o modelo tende a gerar imagens com padrões recorrentes de cor, textura ou estrutura, reduzindo a diversidade do conjunto sintético gerado (GOODFELLOW, 2016).

2.4 Modelos de Difusão Latente e Arquiteturas Híbridas Encoder-Difusor

Uma limitação prática dos DDPMs operando no espaço de pixels é o elevado custo computacional de treinamento e inferência, visto que cada etapa do processo de desrruído exige avaliações sobre tensores de alta dimensionalidade. Os Modelos de Difusão Latente (*Latent Diffusion Models*, LDMs) contornam essa limitação aplicando o processo de difusão no espaço latente comprimido de um autoencoder pré-treinado tipicamente um Autoencoder Variacional (*Variational Autoencoder*, VAE) , que mapeia a imagem original para uma representação de menor dimensionalidade e, a partir das amostras latentes geradas pelo difusor, as decodifica de volta ao espaço de imagens. Essa abordagem viabilizou a geração de imagens de alta resolução com custo computacional substancialmente inferior ao dos DDPMs no espaço de pixels, tornando o treinamento acessível a hardware de uso geral e possibilitando sua adoção em larga escala, inclusive como base do Stable Diffusion (ROMBACH *et al.*, 2022).

A arquitetura Encoder-Difusor pode ser entendida como uma instância específica desse paradigma, em que o encoder é responsável por extrair uma representação latente compacta e semanticamente coerente das imagens de treinamento, enquanto o modelo de difusão aprende a distribuição dessas representações e é capaz de amostrar novas representações latentes que, ao serem decodificadas, produzem imagens sintéticas realistas. A qualidade das representações latentes tem impacto direto sobre a qualidade das imagens geradas. O LiteVAE, uma variante do VAE que utiliza a transformada discreta de wavelet 2D para codificação eficiente, reduz em seis vezes o número de parâmetros do encoder sem sacrifício de qualidade, o que é especialmente relevante para implantações com recursos computacionais limitados (SADAT *et al.*, 2024).

A avaliação da qualidade de imagens sintéticas é tipicamente realizada por meio do FID (Fréchet Inception Distance), que mede a distância entre a distribuição das imagens reais e a das imagens sintéticas no espaço de características de uma rede Inception pré-treinada: valores menores indicam maior semelhança distribucional. Métricas complementares incluem SSIM (Structural Similarity Index Measure), LPIPS (Learned Perceptual Image Patch Similarity) e PSNR (Peak Signal-to-Noise Ratio). No contexto de imagens médicas, a avaliação qualitativa por especialistas também é essencial para garantir que as imagens sintéticas preservam estruturas anatomopatológicas relevantes para o diagnóstico.

REFERÊNCIAS

- ALZHRANI, A.; RAZA, M. A.; ASGHAR, M. Z. Demystifying diagnosis: an efficient deep learning technique with explainable AI to improve breast cancer detection. *PeerJ Computer Science*, 2025.
- CAO, Z. et al. Diffusion model-based medical image generation as a potential data augmentation strategy for AI applications. *Current Medical Imaging*, 2025.
- GOODFELLOW, I. et al. Generative adversarial nets. In: *Advances in Neural Information Processing Systems (NIPS)*. 2014.
- GUERRERO, R. E. D. et al. A data augmentation methodology to reduce the class imbalance in histopathology images. *Journal of Imaging Informatics in Medicine*, v. 37, p. 1767–1782, 2024.
- KHADER, F. et al. Denoising diffusion probabilistic models for 3D medical image generation. *Scientific Reports*, v. 13, 2023.
- LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, v. 521, n. 7553, p. 436–444, 2015.
- MAN, R.; YANG, P.; XU, B. Classification of breast cancer histopathological images using discriminative patches screened by generative adversarial networks. *IEEE Access*, v. 8, p. 155362–155377, 2020.
- MBOUOBDA, J. K. B.; DJAGBA, P. Deep transfer learning for breast cancer classification. *International Journal of Research and Scientific Innovation*, 2025.
- RAHMAN, M. A. et al. Advancements in breast cancer detection: a review of global trends, risk factors, imaging modalities, machine learning, and deep learning approaches. *BioMedInformatics*, 2025.
- ROMBACH, R. et al. High-resolution image synthesis with latent diffusion models. In: *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022. p. 10674–10685.
- SADAT, S. et al. LiteVAE: lightweight and efficient variational autoencoders for latent diffusion models. *ArXiv*, abs/2405.14477, 2024.

- SARAGIH, D. G.; HIBI, A.; TYRRELL, P. N. Using diffusion models to generate synthetic labeled data for medical image segmentation. *International Journal of Computer Assisted Radiology and Surgery*, v. 19, p. 1615–1625, 2023.
- ZHOU, Y. et al. ResViT-GANNet: a deep learning framework for classifying breast cancer histopathology images using multimodal attention and GAN-based augmentation. *BMC Medical Imaging*, v. 25, 2025.
- BONACHO, T. et al. Immunohistochemistry for diagnosis and prognosis of breast cancer: a review. *Biotechnic & Histochemistry*, 2020.
- GOODFELLOW, Ian. Nips 2016 tutorial: Generative adversarial networks. *arXiv preprint arXiv:1701.00160*, 2016.