

**SISTEMA HÍBRIDO BASEADO EM ENCODERS E  
DIFUSORES PARA AUMENTO DE DADOS EM  
IMAGENS DE HISTOLOGIA DO CÂNCER DE MAMA**

**[NOME DO AUTOR]**

**[INSTITUIÇÃO DE ENSINO]**

**[CURSO DE MBA]**

**[LOCAL]**

**2026**

**[NOME DO AUTOR]**

**SISTEMA HÍBRIDO BASEADO EM ENCODERS E  
DIFUSORES PARA AUMENTO DE DADOS EM  
IMAGENS DE HISTOLOGIA DO CÂNCER DE MAMA**

Trabalho de Conclusão de Curso apresentado ao **[Curso de MBA]** da **[Instituição de Ensino]**, como requisito parcial para obtenção do título de especialista em **[área do curso]**.

Orientador(a): **[NOME DO(A) ORIENTADOR(A)]**.

**[LOCAL]**

**2026**

## RESUMO

A escassez de imagens histopatológicas rotuladas e o desbalanceamento entre classes dificultam o treinamento de classificadores robustos para apoio computacional ao diagnóstico do câncer de mama. Este trabalho propõe, implementa e avalia um sistema híbrido Encoder-Difusor para aumento de dados no conjunto BreakHis, composto por imagens histopatológicas de tecido mamário benigno e maligno. O sistema utiliza um Autoencoder Variacional pré-treinado, empregado como codificador latente, e um Modelo de Difusão Latente condicionado pelos oito subtipos histológicos do BreakHis. O protocolo experimental preservou uma divisão estratificada por paciente, a fim de evitar vazamento de dados entre treino, validação e teste. Inicialmente, avaliou-se a classificação em oito subtipos, mas os resultados revelaram instabilidade associada ao pequeno número de pacientes em classes raras. Diante disso, o endpoint downstream principal foi refinado para classificação binária benigno versus maligno, mantendo a geração condicionada por subtipo. Foram comparados três cenários: treinamento com dados reais, treinamento com aumento clássico e treinamento com dados reais combinados a imagens sintéticas geradas pelo LDM. Também foi conduzida ablação da proporção sintética, com variantes C100, C25 e C50\_full, além de calibração de threshold baseada na validação. O melhor resultado completo foi obtido pelo C50\_full calibrado, com acurácia de 88,02%, balanced accuracy de 86,73%, F1 macro de 86,46% e AUC de 92,22%. O C25 apresentou a maior AUC entre os experimentos completos, com 94,05%. Na análise estatística exploratória, o teste exato de McNemar por imagem indicou diferença significativa entre o baseline binário e o C50\_full calibrado ( $p = 0,017169$ ), enquanto o bootstrap por paciente apresentou efeitos positivos, porém com intervalos de confiança conservadores devido aos 17 pacientes no teste. A avaliação gerativa indicou FID global de 219,668, SSIM baixo e LPIPS alto, sugerindo que as imagens sintéticas não substituem adequadamente a distribuição visual real. Conclui-se que a hipótese foi parcialmente confirmada e

refinada: o sistema Encoder-Difusor mostrou-se promissor como augmentação controlada para classificação binária, embora não tenha validado plenamente o cenário de oito subtipos nem produzido alta fidelidade gerativa.

**Palavras-chave:** histopatologia; câncer de mama; BreakHis; modelos de difusão latente; aumento de dados; classificação binária.

## ABSTRACT

The scarcity of labeled histopathological images and class imbalance make it difficult to train robust classifiers for computational support in breast cancer diagnosis. This work proposes, implements, and evaluates a hybrid Encoder-Diffuser system for data augmentation on the BreakHis dataset, composed of histopathological images of benign and malignant breast tissue. The system uses a pretrained Variational Autoencoder as a latent encoder and a Latent Diffusion Model conditioned on the eight histological subtypes of BreakHis. The experimental protocol preserved a stratified patient-wise split to avoid data leakage between training, validation, and test sets. Initially, the eight-subtype classification task was evaluated, but the results revealed instability associated with the small number of patients in rare classes. Therefore, the main downstream endpoint was refined to binary benign versus malignant classification, while subtype-conditioned generation was preserved. Three scenarios were compared: training with real data, training with classical augmentation, and training with real data combined with synthetic images generated by the LDM. An ablation of the synthetic proportion was also conducted, with C100, C25, and C50\_full variants, as well as validation-based threshold calibration. The best complete result was obtained by calibrated C50\_full, with 88.02% accuracy, 86.73% balanced accuracy, 86.46% macro F1, and 92.22% AUC. C25 achieved the highest AUC among complete experiments, with 94.05%. In the exploratory statistical analysis, the exact image-level McNemar test indicated a significant difference between the binary baseline and calibrated C50\_full ( $p = 0.017169$ ), while patient-level bootstrap showed positive effects with conservative confidence intervals due to the 17 patients in the test set. Generative evaluation indicated a global FID of 219.668, low SSIM, and high LPIPS, suggesting that synthetic images do not adequately replace the real visual distribution. The hypothesis is therefore partially confirmed and refined: the Encoder-Diffuser system is promising as controlled augmentation for binary

classification, although it did not fully validate the eight-subtype scenario nor achieve high generative fidelity.

**Keywords:** histopathology; breast cancer; BreakHis; latent diffusion models; data augmentation; binary classification.

## **LISTA DE TABELAS**

Tabela 1 - Particionamento patient-wise do BreakHis no experimento

Tabela 2 - Configuração resumida do LDM

Tabela 3 - Resultados do protocolo inicial com oito subtipos

Tabela 4 - Resultados binários iniciais

Tabela 5 - Comparativo binário com ablação de sintéticas

Tabela 6 - Matrizes de confusão do baseline A e do C50\_full calibrado

Tabela 7 - Testes estatísticos entre A e C50\_full calibrado

Tabela 8 - Métricas gerativas por subtipo

## **LISTA DE ABREVIATURAS E SIGLAS**

AUC - Area Under the Curve

CNN - Convolutional Neural Network

DDIM - Denoising Diffusion Implicit Model

DDPM - Denoising Diffusion Probabilistic Model

FID - Fréchet Inception Distance

FP32 - Floating Point 32-bit

H&E - Hematoxilina e eosina

IC - Intervalo de confiança

LDM - Latent Diffusion Model

LPIPS - Learned Perceptual Image Patch Similarity

PSNR - Peak Signal-to-Noise Ratio

SSIM - Structural Similarity Index Measure

TCC - Trabalho de Conclusão de Curso

VAE - Variational Autoencoder



## SUMÁRIO

### 1. INTRODUÇÃO

### 2. FUNDAMENTAÇÃO TEÓRICA

#### 2.1 Histopatologia do câncer de mama e classificação computacional

#### 2.2 O conjunto BreakHis e o risco de vazamento por paciente

#### 2.3 Aumento de dados em imagens médicas

#### 2.4 GANs, DDPMs e modelos de difusão latente

#### 2.5 Avaliação de imagens sintéticas médicas

### 3. METODOLOGIA

#### 3.1 Caracterização da base de dados

#### 3.2 Organização, metadados e split por paciente

#### 3.3 Arquitetura Encoder-Difusor

#### 3.4 Geração de imagens sintéticas

#### 3.5 Protocolo downstream e virada metodológica

#### 3.6 Métricas e testes estatísticos

### 4. RESULTADOS

#### 4.1 Protocolo inicial em oito subtipos

#### 4.2 Resultados binários A, B e C100

#### 4.3 Ablação C25, C50\_full e C100

#### 4.4 Matrizes de confusão

#### 4.5 Testes estatísticos

#### 4.6 Avaliação gerativa

#### 4.7 Síntese dos resultados

### 5. DISCUSSÃO

### 6. CONCLUSÃO

### REFERÊNCIAS

## 1 INTRODUÇÃO

O câncer de mama permanece como um dos principais problemas de saúde pública no mundo e seu diagnóstico definitivo depende, em grande parte, da avaliação histopatológica de amostras de tecido. A análise microscópica de lâminas coradas por hematoxilina e eosina permite observar padrões morfológicos associados a lesões benignas e malignas, mas exige conhecimento especializado, tempo de leitura e consistência interpretativa. Com a expansão da patologia digital, tornou-se possível aplicar métodos computacionais a imagens histológicas, abrindo espaço para sistemas de apoio ao diagnóstico baseados em aprendizado profundo.

Modelos de aprendizado profundo têm alcançado desempenho expressivo em tarefas de classificação de imagens histopatológicas de mama. Revisões recentes destacam avanços em arquiteturas convolucionais, transformers, mecanismos de atenção, aprendizagem por transferência, explicabilidade e integração clínica, mas também apontam desafios persistentes relacionados à heterogeneidade morfológica, variações de coloração, escassez de bases anotadas e necessidade de validação experimental rigorosa (HAQ et al., 2025). Em imagens médicas, esses desafios são particularmente sensíveis porque a coleta e a rotulação de dados dependem de disponibilidade institucional, privacidade, infraestrutura laboratorial e especialistas.

O conjunto BreakHis tornou-se uma das bases públicas mais utilizadas para classificação histopatológica do câncer de mama. O artigo original descreve 7.909 imagens obtidas de 82 pacientes, distribuídas entre amostras benignas e malignas e adquiridas em quatro fatores de magnificação microscópica (SPANHOL et al., 2016). No presente trabalho, o pipeline local extrai e confirmou 7.909 imagens associadas a 81 pacientes válidos nos arquivos disponíveis. Essa diferença é registrada sem alterar a natureza do conjunto: trata-se de uma base com muitas imagens, porém poucos pacientes, o que torna a

estratégia de divisão dos dados decisiva para a validade dos resultados.

A divisão por imagem, frequente em avaliações de bases histopatológicas, pode permitir que imagens de um mesmo paciente apareçam simultaneamente em treino e teste. Como imagens do mesmo paciente compartilham características teciduais, padrões de aquisição e correlações biológicas, esse desenho tende a inflar o desempenho estimado. Avaliações recentes no BreakHis reforçam que protocolos patient-aware são necessários para reduzir vazamento de dados e produzir estimativas mais realistas de generalização (PRIYANKA; NARENDRA; RAO, 2026). Por esse motivo, este estudo adotou split estratificado por paciente em todas as etapas experimentais.

A dificuldade de treinar modelos robustos com bases pequenas e desbalanceadas motiva o uso de aumento de dados. Transformações clássicas, como rotações, espelhamentos e alterações fotométricas, são úteis e baratas, mas derivam novas amostras diretamente de imagens existentes. Modelos generativos, por sua vez, buscam aprender uma distribuição de dados capaz de produzir novas amostras sintéticas. Entre eles, as GANs foram uma das primeiras famílias amplamente utilizadas para síntese de imagens, baseadas em um jogo adversarial entre gerador e discriminador (GOODFELLOW et al., 2014). Apesar de sua importância, modelos adversariais podem apresentar instabilidade de treinamento e limitações de diversidade, sobretudo em cenários de poucos dados.

Modelos de difusão probabilística surgiram como uma alternativa relevante para síntese de imagens. O DDPM aprende a reverter gradualmente um processo de adição de ruído, permitindo gerar amostras de alta qualidade sem treinamento adversarial (HO; JAIN; ABBEEL, 2020). Os modelos de difusão latente reduzem o custo computacional ao aplicar a difusão em um espaço comprimido por autoencoders, mantendo flexibilidade de condicionamento e qualidade de síntese com menor demanda de recursos do que a difusão diretamente em pixels (ROMBACH et al., 2022). Em imagem médica, revisões

recentes registram crescimento do uso de difusão em tarefas de síntese, tradução, reconstrução, segmentação, classificação e aumento de dados (KAZEROUNI et al., 2022).

Neste contexto, o presente trabalho propõe um sistema híbrido Encoder-Difusor para aumento de dados em imagens histopatológicas de câncer de mama. O sistema utiliza um Autoencoder Variacional como codificador latente e um Modelo de Difusão Latente condicionado por subtipo histológico para gerar imagens sintéticas. A hipótese inicial era que esse sistema superaria o treinamento sem aumento e o aumento clássico tanto em qualidade gerativa quanto em desempenho downstream. Entretanto, a execução experimental revelou um cenário mais nuançado: a classificação em oito subtipos mostrou-se instável sob split por paciente, enquanto a classificação binária benigno versus maligno apresentou ganhos quando as imagens sintéticas foram usadas em proporção controlada.

Assim, o objetivo geral deste trabalho é desenvolver e avaliar um sistema híbrido Encoder-Difusor para aumento de dados em imagens histopatológicas do BreakHis, analisando seu impacto na qualidade das imagens sintéticas e no desempenho de classificadores downstream. Os objetivos específicos são: organizar a base com extração de metadados e split estratificado por paciente; implementar um LDM condicionado por subtipo; gerar imagens sintéticas; comparar o treinamento sem aumento, o aumento clássico e o aumento generativo; avaliar a proporção de sintéticas no treinamento binário; aplicar calibração de threshold com base na validação; realizar análise estatística exploratória; e discutir criticamente os limites do método.

A contribuição do estudo é dupla. Do ponto de vista técnico, entrega-se um pipeline reproduzível de geração e avaliação downstream baseado em VAE e LDM. Do ponto de vista metodológico, mostra-se que dados sintéticos por difusão podem ajudar como augmentação controlada, mas não substituem automaticamente dados reais nem resolvem, por si só, a fragilidade estatística de classes com poucos pacientes. Portanto, a conclusão científica não é de validação plena da

hipótese original, mas de refinamento: o método é promissor no downstream binário, com limitações claras no cenário de oito subtipos e na fidelidade gerativa.

## **2 FUNDAMENTAÇÃO TEÓRICA**

### **2.1 Histopatologia do câncer de mama e classificação computacional**

A histopatologia é uma etapa central do diagnóstico do câncer de mama, pois permite observar alterações celulares e teciduais associadas a diferentes tipos de lesão. Em bases digitais, essas informações são capturadas como imagens microscópicas, frequentemente em múltiplas magnificações. A classificação automática dessas imagens busca associar padrões visuais a classes diagnósticas, como benigno e maligno, ou a subtipos histológicos mais específicos.

A aplicação de aprendizado profundo à histopatologia depende da capacidade dos modelos de extrair padrões morfológicos relevantes, como organização celular, textura, densidade nuclear, presença de estruturas glandulares e variações de coloração. Arquiteturas convolucionais são amplamente utilizadas por capturarem padrões locais em imagens, enquanto arquiteturas mais recentes incluem mecanismos de atenção e transformers para explorar relações de maior alcance. Ainda assim, a performance desses modelos está ligada não apenas à arquitetura, mas também ao desenho experimental, à quantidade de pacientes, ao balanceamento entre classes e ao controle de vazamento de dados.

A literatura recente sobre análise histopatológica de mama destaca que, embora resultados altos sejam frequentemente reportados, a translação clínica exige maior rigor experimental, validação externa, interpretabilidade e cuidado com vieses do conjunto de dados (HAQ et al., 2025). Assim, a avaliação de modelos para histologia não deve se limitar à acurácia global, especialmente quando há desbalanceamento entre classes ou dependência estatística entre imagens de um mesmo paciente.

## 2.2 O conjunto BreakHis e o risco de vazamento por paciente

O BreakHis foi introduzido como uma base pública para classificação de imagens histopatológicas de câncer de mama, contendo imagens benignas e malignas em quatro magnificações: 40x, 100x, 200x e 400x. O estudo original descreve 7.909 imagens obtidas de 82 pacientes, com acurácias preliminares entre 80% e 85% em classificadores do estado da arte à época, indicando margem para avanço metodológico (SPANHOL et al., 2016).

No presente trabalho, a extração local resultou em 7.909 imagens associadas a 81 pacientes confirmados no pipeline. As imagens foram organizadas em oito subtipos histológicos: adenosis, fibroadenoma, phyllodes\_tumor, tubular\_adenoma, ductal\_carcinoma, lobular\_carcinoma, mucinous\_carcinoma e papillary\_carcinoma. Esses subtipos se agrupam em duas classes diagnósticas: benigno e maligno.

O aspecto crítico do BreakHis, para fins de avaliação downstream, é que o número de imagens não reflete o número real de unidades independentes. Um mesmo paciente pode contribuir com dezenas ou centenas de imagens, gerando forte correlação intra-paciente. Se o particionamento for feito no nível da imagem, amostras do mesmo paciente podem aparecer em treino e teste, produzindo vazamento de informação e estimativas excessivamente otimistas. Priyanka, Narendra e Rao (2026) enfatizam justamente essa questão ao propor uma avaliação patient-aware de arquiteturas CNN e transformer no BreakHis, argumentando que o desenho de avaliação pode ser mais determinante que diferenças marginais entre arquiteturas.

Por isso, este TCC adota a divisão por paciente como requisito metodológico. Essa decisão torna o problema mais difícil, mas também torna os resultados mais defensáveis. Ela é especialmente importante na análise dos oito subtipos, pois algumas classes possuem pouquíssimos pacientes, situação que limita a capacidade de generalização e torna métricas como F1 macro mais informativas que a acurácia global.

### **2.3 Aumento de dados em imagens médicas**

Aumento de dados é uma estratégia para reduzir sobreajuste e ampliar a diversidade observada pelo modelo durante o treinamento. Em imagens histopatológicas, transformações geométricas como rotações e espelhamentos podem ser plausíveis, pois muitos tecidos não possuem orientação fixa no plano da lâmina. Transformações fotométricas, como brilho, contraste e saturação, podem simular variações de coloração e aquisição.

Entretanto, o aumento clássico permanece limitado por operar sobre imagens já existentes. Ele modifica amostras observadas, mas não necessariamente introduz novas variações histológicas. Por isso, revisões sobre aumento de dados em imagem médica têm destacado modelos generativos profundos, incluindo VAEs, GANs e modelos de difusão, como alternativas para produzir amostras mais diversas e potencialmente úteis em tarefas downstream (KEBAILI; LAPUYADE-LAHORGUE; RUAN, 2023).

Ainda assim, dados sintéticos devem ser tratados com cautela. Estudos com modelos de difusão latente em classificadores médicos sugerem que imagens sintéticas podem atuar como multiplicadores de dados em cenários limitados, mas os ganhos podem saturar e tendem a ser menores do que os ganhos obtidos pela inclusão de dados reais adicionais (SAGERS et al., 2023). Essa observação é central para a interpretação deste trabalho: dados sintéticos são avaliados como augmentação controlada, não como substituição da distribuição real.

### **2.4 GANs, DDPMs e modelos de difusão latente**

As redes adversariais generativas foram propostas como um método para estimar distribuições de dados por meio de um processo adversarial. Um gerador tenta produzir amostras capazes de enganar um discriminador, enquanto o discriminador aprende a distinguir amostras reais de sintéticas. Esse jogo minimax abriu caminho para avanços importantes em síntese de

imagens (GOODFELLOW et al., 2014). Contudo, a dinâmica adversarial também introduz desafios de estabilidade, diversidade e convergência, especialmente em conjuntos pequenos e desbalanceados.

Os modelos de difusão probabilística seguem outra abordagem. Em vez de treinar um gerador contra um discriminador, eles definem um processo direto que adiciona ruído aos dados e treinam uma rede para reverter progressivamente esse processo. Ho, Jain e Abbeel (2020) demonstraram que DDPMs podem produzir imagens de alta qualidade e bons valores de FID em benchmarks naturais. O custo, porém, é a amostragem iterativa com muitos passos.

Os DDIMs foram propostos para acelerar a geração, mantendo o mesmo objetivo de treinamento dos DDPMs e permitindo amostragem mais rápida por processos não markovianos (SONG; MENG; ERMON, 2020). Essa redução de custo é útil em cenários aplicados, nos quais a geração de milhares de imagens por classe pode se tornar inviável com amostragem completa.

Os modelos de difusão latente reduzem ainda mais o custo ao deslocar o processo de difusão do espaço de pixels para um espaço latente comprimido por autoencoders. Rombach et al. (2022) mostram que essa estratégia preserva qualidade e flexibilidade de condicionamento, ao mesmo tempo que reduz as exigências computacionais frente a modelos de difusão em pixels. Essa característica justifica a escolha de um pipeline Encoder-Difusor neste TCC, já que a infraestrutura disponível possui limitação de VRAM.

Na área médica, Kazerouni et al. (2022) apresentam uma revisão abrangente de modelos de difusão em imagem médica, incluindo aplicações em síntese, reconstrução, tradução, segmentação e classificação. Além disso, Müller-Franzes et al. (2022) compararam modelos latentes de difusão e GANs em múltiplas modalidades médicas, incluindo histopatologia, relatando maior diversidade e fidelidade para o modelo de difusão avaliado. Essa evidência apoia a escolha conceitual por



difusão, embora este trabalho não implemente um baseline GAN próprio. Em histopatologia, Osório et al. (2023) também exploram modelos de difusão latente com anotações derivadas de imagem para apoio a diagnóstico oncológico, reforçando a pertinência do uso dessa família de modelos no domínio histopatológico, ainda que em desenho experimental distinto do presente trabalho.

## **2.5 Avaliação de imagens sintéticas médicas**

A avaliação de imagens sintéticas médicas não pode depender de uma única métrica. FID, SSIM, LPIPS e PSNR oferecem perspectivas complementares sobre distância distribucional, similaridade estrutural, distância perceptual e distorção pixel a pixel. Contudo, essas métricas não determinam sozinhas se uma imagem é clinicamente adequada ou histologicamente plausível.

Abdusalomov et al. (2023) discutem que ainda não há métodos plenamente satisfatórios para avaliar a adequação médica de imagens sintéticas, pois métricas baseadas em similaridade ou distribuição podem deixar de capturar repetição, memorização ou validade clínica. Em patologia digital, Pozzi et al. (2024) defendem uma avaliação multifacetada que combine métricas real-sintético, utilidade downstream, explicabilidade e verificação por patologistas.

Esse ponto é fundamental para a leitura dos resultados deste TCC. Um FID alto deve ser reconhecido como limitação gerativa real. No entanto, o impacto downstream deve ser avaliado separadamente: uma imagem sintética visualmente imperfeita ainda pode introduzir variação útil para regularizar o treinamento de classificadores. Por isso, o trabalho mede tanto a qualidade gerativa quanto o desempenho downstream.

## **3 METODOLOGIA**

Este capítulo descreve os procedimentos adotados para implementar e avaliar o sistema híbrido Encoder-Difusor. A metodologia compreende: caracterização do BreakHis; extração de metadados; divisão estratificada por paciente; implementação

do VAE e do LDM condicionado por subtipo; geração de imagens sintéticas; treinamento downstream; ablação da proporção sintética; calibração de threshold; avaliação gerativa; e análise estatística.

### 3.1 Caracterização da base de dados

A base utilizada foi o BreakHis, composta por imagens histopatológicas de câncer de mama em formato PNG, obtidas em quatro magnificações microscópicas. O artigo original descreve 7.909 imagens provenientes de 82 pacientes (SPANHOL et al., 2016). No ambiente experimental deste trabalho, a base extraída em `data/raw/BreakHis_v1/BreakHis_v1/histology_slides/breast/` resultou em 7.909 imagens e 81 pacientes confirmados após processamento local.

As imagens foram categorizadas em oito subtipos histológicos. Quatro subtipos pertencem à classe benigna: `adenosis`, `fibroadenoma`, `phylloides_tumor` e `tubular_adenoma`. Quatro pertencem à classe maligna: `ductal_carcinoma`, `lobular_carcinoma`, `mucinous_carcinoma` e `papillary_carcinoma`. Para os experimentos de classificação, foram mantidos dois rótulos: `label_8`, correspondente aos oito subtipos, e `label_2`, correspondente à classe binária benigno versus maligno.

### 3.2 Organização, metadados e split por paciente

A organização dos dados foi realizada por varredura recursiva do diretório da base. Para cada imagem foram extraídos: caminho do arquivo, classe diagnóstica, subtipo, abreviação do rótulo, magnificação, identificador de paciente, rótulo de oito classes e rótulo binário. O identificador de paciente foi extraído do nome do arquivo por expressão regular compatível com o padrão real do BreakHis. A magnificação foi extraída da pasta de origem, e não do nome do arquivo.

A divisão dos dados seguiu proporção 70% treino, 10% validação e 20% teste, com semente 42. A unidade de divisão foi

o paciente. Assim, nenhum paciente aparece em mais de um subconjunto. O particionamento final foi:

**Tabela 1 - Particionamento patient-wise do BreakHis no experimento**

| Subconjunto | Imagens | % do total | Pacientes |
|-------------|---------|------------|-----------|
| Treinamento | 4.892   | 61,9%      | 53        |
| Validação   | 1.514   | 19,1%      | 11        |
| Teste       | 1.503   | 19,0%      | 17        |
| Total       | 7.909   | 100,0%     | 81        |

Fonte: elaborado pelo autor com base no processamento local do BreakHis.

A ausência de sobreposição de pacientes foi verificada explicitamente:  $\text{train} \cap \text{val} = 0$ ,  $\text{train} \cap \text{test} = 0$  e  $\text{val} \cap \text{test} = 0$ . Essa decisão metodológica foi mantida mesmo com perda de estabilidade em classes raras, pois avaliações patient-wise reduzem o risco de data leakage e são mais realistas para estimar generalização (PRIYANKA; NARENDRA; RAO, 2026).

Durante a divisão, identificou-se que alguns subtipos possuíam pouquíssimos pacientes. O caso mais crítico foi `phyllodes_tumor`, com três pacientes no total, ficando um em treino, um em validação e um em teste. Essa distribuição preserva o teste intacto, mas torna o sinal de validação instável para oito subtipos. A limitação é inerente à base sob split por paciente e foi decisiva para a redefinição do endpoint principal.

### 3.3 Arquitetura Encoder-Difusor

O sistema proposto possui dois módulos. O primeiro é um Autoencoder Variacional, usado como encoder e decoder de imagens. O segundo é um Modelo de Difusão Latente condicionado por subtipo histológico.

O VAE adotado foi o `stabilityai/sd-vae-ft-mse`, utilizado congelado. Ele mapeia imagens redimensionadas para 256 x 256 pixels para latentes com quatro canais e resolução

espacial reduzida. A escolha por congelar o VAE foi motivada por restrição de hardware: o fine-tuning estimado com batch pequeno demandaria tempo incompatível com o escopo do trabalho na GPU disponível. Essa decisão é registrada como limitação metodológica, pois um VAE ajustado ao domínio histopatológico poderia melhorar a fidelidade das reconstruções.

O LDM foi implementado com uma U-Net condicional no espaço latente. O condicionamento foi realizado por embedding aprendido dos oito subtipos histológicos. Foi incluído um índice nulo para classifier-free guidance, permitindo que o modelo aprendesse versões condicionais e incondicionais do processo de denoising. O objetivo de treinamento seguiu a formulação de predição de ruído típica dos DDPMs (HO; JAIN; ABBEEL, 2020), aplicada ao espaço latente, conforme a lógica de difusão latente proposta por Rombach et al. (2022).

**Tabela 2 - Configuração resumida do LDM**

| Parâmetro                       | Valor     |
|---------------------------------|-----------|
| Timesteps de difusão            | 1.000     |
| Resolução da imagem             | 256 x 256 |
| Canais latentes                 | 4         |
| Dimensão do embedding de classe | 512       |
| Número de classes condicionais  | 8         |
| Batch size do LDM               | 8         |
| Épocas máximas                  | 100       |
| Learning rate                   | 1,0e-4    |
| Early stopping                  | 15 épocas |
| Precisão numérica               | FP32      |

Fonte: elaborado pelo autor com base nos arquivos de configuração e execução do experimento.

O treinamento foi conduzido em FP32. Tentativas com AMP/FP16 produziram instabilidade numérica e valores NaN na loss, motivo pelo qual foram descartadas. Foram adicionadas

proteções contra NaN nos latentes e na loss, além de clipping de gradiente.

### 3.4 Geração de imagens sintéticas

A geração foi realizada a partir do checkpoint `checkpoints/ldm/best.pt`. A amostragem utilizou DDIM com 50 passos, reduzindo o custo de inferência em relação ao processo DDPM completo. Essa escolha é coerente com a proposta de Song, Meng e Ermon (2020), que introduz DDIM como uma alternativa de amostragem mais rápida para modelos de difusão.

As imagens foram geradas por subtipo, seguindo uma estratégia inicial de equalização: para cada subtipo, o número de imagens sintéticas foi definido pela diferença entre a contagem do subtipo majoritário no treino e a contagem do subtipo em questão. O subtipo `ductal_carcinoma` não recebeu sintéticas, pois já era a classe majoritária. As imagens foram salvas em `data/synthetic/{subtipo}/`.

Posteriormente, a equalização completa passou a ser tratada como variante C100. Para investigar se o volume sintético poderia diluir a distribuição real, foram criadas ablações com 25% e 50% das sintéticas geradas, denominadas C25 e C50\_full.

### 3.5 Protocolo downstream e virada metodológica

O protocolo experimental começou com a hipótese de que o sistema Encoder-Difusor melhoraria o desempenho em oito subtipos. Os cenários originais foram:

- Cenário A: treinamento com imagens reais do BreakHis.
- Cenário B: treinamento com imagens reais e aumento clássico online.
- Cenário C100: treinamento com imagens reais e 100% das sintéticas geradas pelo LDM.

O classificador usado no protocolo inicial foi EfficientNet-B0 com pesos ImageNet. EfficientNet foi escolhido por sua eficiência paramétrica e por seu método de

escalonamento composto, que equilibra profundidade, largura e resolução (TAN; LE, 2019). Os hiperparâmetros foram mantidos constantes entre cenários, de modo que a principal variável fosse a composição do treino.

Os resultados do protocolo de oito subtipos indicaram instabilidade severa. A baixa quantidade de pacientes em subtipos raros tornou a macro F1 pouco robusta e prejudicou a seleção de checkpoint. Assim, o estudo adotou uma virada metodológica: a classificação binária benigno versus maligno passou a ser o endpoint downstream principal, enquanto os oito subtipos permaneceram relevantes para condicionamento do LDM e análise exploratória.

No protocolo binário, foram avaliados:

- A binário: reais, sem aumento. - B binário: reais com aumento clássico. - C100 binário: reais + 100% das sintéticas. - C25 binário: reais + 25% das sintéticas. - C50\_full binário: reais + 50% das sintéticas. - C25 calibrado e C50\_full calibrado: limiar definido na validação e aplicado no teste.

A calibração de threshold foi feita exclusivamente no conjunto de validação, maximizando balanced accuracy. O teste permaneceu reservado para avaliação final.

### 3.6 Métricas e testes estatísticos

O desempenho downstream foi avaliado por acurácia, balanced accuracy, F1 macro, AUC e matriz de confusão. A acurácia foi mantida por ser intuitiva, mas balanced accuracy, F1 macro e AUC receberam maior peso interpretativo por causa do desbalanceamento de classes. As tabelas comparativas adotam como fonte principal o consolidado de ablação binária; eventuais diferenças centesimais em relatórios auxiliares decorrem de recálculo pareado a partir dos escores salvos e não alteram o ranking interpretado.

A qualidade gerativa foi avaliada por FID, SSIM, LPIPS e PSNR. O FID global foi calculado de forma amostrada sobre subtipos com imagens sintéticas. SSIM, LPIPS e PSNR foram

calculados por pares amostrados por subtipo. Essas métricas foram interpretadas como indicadores quantitativos, não como validação clínica, em consonância com a cautela apontada por Abdusalomov et al. (2023) e Pozzi et al. (2024).

A comparação estatística exploratória principal foi entre A binário e C50\_full calibrado. Foram aplicados dois procedimentos: teste exato de McNemar por imagem e bootstrap por paciente com 5.000 reamostragens. O McNemar por imagem oferece maior poder estatístico, mas assume independência no nível da imagem; o bootstrap por paciente é mais conservador e respeita a estrutura patient-wise do BreakHis, embora sofra com apenas 17 pacientes no teste.

## 4 RESULTADOS

### 4.1 Protocolo inicial em oito subtipos

A Tabela 3 apresenta os resultados do protocolo original com oito subtipos. Esse protocolo foi importante por revelar a limitação do desenho inicial sob split por paciente.

**Tabela 3 - Resultados do protocolo inicial com oito subtipos**

| Cenário | Dados de treinamento        | Accuracy | F1 macro |
|---------|-----------------------------|----------|----------|
| A       | BreakHis original           | 49,83%   | 27,71%   |
| B       | BreakHis + aumento clássico | 41,52%   | 22,26%   |
| C100    | BreakHis + sintéticas LDM   | 43,98%   | 24,95%   |

Fonte: elaborado pelo autor com base nos resultados experimentais do protocolo inicial.

A hipótese forte  $C > B > A$  não se sustentou no cenário de oito subtipos. O aumento clássico reduziu tanto acurácia quanto F1 macro. O C100 recuperou parte da perda observada em B, mas permaneceu abaixo do baseline A. A análise qualitativa dos resultados indicou tendência do classificador a favorecer ductal\_carcinoma, classe majoritária no treino, enquanto subtipos raros foram pouco reconhecidos.

Essa etapa não deve ser interpretada como simples falha do modelo. O problema central foi estatístico: sob split patient-wise, algumas classes têm representação extremamente pequena em número de pacientes. Phyllodes\_tumor, por exemplo, possui apenas um paciente em treino, um em validação e um em teste. A macro F1 penaliza fortemente esse desequilíbrio, como deve ocorrer em uma avaliação honesta. Portanto, o resultado negativo serviu como diagnóstico da inviabilidade prática de sustentar os oito subtipos como endpoint principal neste conjunto e nesta infraestrutura.

#### 4.2 Resultados binários A, B e C100

Ao reformular o downstream para classificação binária benigno versus maligno, o desempenho tornou-se substancialmente mais estável. A Tabela 4 mostra os três cenários iniciais.

**Tabela 4 - Resultados binários iniciais**

| Cenário | Accuracy | Balanced accuracy | F1 macro | AUC    |
|---------|----------|-------------------|----------|--------|
| A       | 85,89%   | 81,13%            | 82,88%   | 89,79% |
| B       | 84,30%   | 81,27%            | 81,80%   | 90,36% |
| C100    | 84,90%   | 82,24%            | 82,60%   | 91,14% |

Fonte: elaborado pelo autor com base nos resultados experimentais binários.

O baseline A alcançou 85,89% de acurácia e F1 macro de 82,88%, mostrando que o pipeline de classificação é funcional quando a tarefa respeita melhor a estrutura estatística da base. O aumento clássico apresentou efeito misto: melhorou discretamente balanced accuracy e AUC, mas reduziu acurácia e F1 macro. O C100 superou B em todas as métricas e superou A em balanced accuracy e AUC, mas ainda ficou ligeiramente abaixo de A em acurácia e F1 macro.

Essa discrepância entre AUC e métricas dependentes de threshold sugeriu que o modelo com sintéticas possuía melhor capacidade de ordenação probabilística, mas não necessariamente o melhor limiar de decisão padrão. Por isso, a



etapa seguinte avaliou ablações de proporção sintética e calibração de threshold.

### 4.3 Ablação C25, C50\_full e C100

A Tabela 5 apresenta a comparação consolidada dos experimentos binários completos.

**Tabela 5 - Comparativo binário com ablação de sintéticas**

| Variante           | Decisão   | Threshold | Accuracy | Balanced accuracy | F1 macro | AUC    |
|--------------------|-----------|-----------|----------|-------------------|----------|--------|
| A                  | Argmax    | -         | 85,89%   | 81,13%            | 82,88%   | 89,79% |
| B                  | Argmax    | -         | 84,30%   | 81,27%            | 81,80%   | 90,36% |
| C100               | Argmax    | -         | 84,90%   | 82,24%            | 82,60%   | 91,14% |
| C25                | Argmax    | -         | 87,56%   | 84,16%            | 85,31%   | 94,05% |
| C50_full           | Argmax    | -         | 87,29%   | 83,81%            | 84,98%   | 92,63% |
| C25 calibrado      | Validação | 0,79      | 87,89%   | 85,20%            | 85,91%   | 93,76% |
| C50_full calibrado | Validação | 0,97      | 88,02%   | 86,73%            | 86,46%   | 92,22% |

Fonte: elaborado pelo autor com base no comparativo de ablacao binaria.

O C25 apresentou a maior AUC entre os experimentos completos, com 94,05%, indicando a maior capacidade de ordenação probabilística entre os experimentos avaliados. O C50\_full calibrado foi o melhor experimento completo em acurácia, balanced accuracy e F1 macro, com 88,02%, 86,73% e 86,46%, respectivamente. Por reunir os maiores valores nas métricas dependentes de decisão balanceada, o C50\_full calibrado foi selecionado como resultado downstream principal.

A comparação C100 versus C25/C50\_full é central. O uso integral das sintéticas não foi superior. Ao contrário, proporções menores produziram melhores resultados. Esse achado refina a hipótese: o LDM ajuda quando suas imagens são usadas como augmentação controlada; mais sintético não

significa necessariamente melhor desempenho. Essa leitura é coerente com Sagers et al. (2023), que descrevem dados sintéticos por LDM como multiplicadores de dados, mas não como substitutos da coleta de dados reais diversos.

#### 4.4 Matrizes de confusão

As matrizes de confusão mostram como o C50\_full calibrado altera o perfil de erros em relação ao baseline.

**Tabela 6 - Matrizes de confusão do baseline A e do C50\_full calibrado**

| Modelo             | Matriz de confusão      |
|--------------------|-------------------------|
| A                  | [[330, 159], [53, 961]] |
| C50_full calibrado | [[406, 83], [97, 917]]  |

Fonte: elaborado pelo autor com base nas matrizes de confusão dos experimentos binários.

Considerando a ordem benigno/maligno, o C50\_full calibrado reduziu falsos positivos benigno -> maligno de 159 para 83. Em contrapartida, aumentou falsos negativos maligno -> benigno de 53 para 97. Esse deslocamento explica o ganho em balanced accuracy e revela que o threshold calibrado favoreceu uma decisão mais equilibrada entre classes, mas também exige cautela se o objetivo for aplicação clínica, pois falsos negativos malignos podem ter custo elevado. Neste trabalho, o threshold calibrado é instrumento experimental, não recomendação clínica.

#### 4.5 Testes estatísticos

A comparação pareada entre A binário e C50\_full calibrado foi avaliada de forma exploratória por McNemar exato por imagem e bootstrap por paciente. Como C50\_full calibrado foi selecionado após a comparação entre variantes, o p-valor deve ser lido como evidência estatística favorável no protocolo estudado, e não como confirmação definitiva independente de pós-seleção.

**Tabela 7 - Testes estatísticos entre A e C50\_full calibrado**

| Teste ou métrica                          | Resultado                              |
|-------------------------------------------|----------------------------------------|
| McNemar exato por imagem                  | $p = 0,017169$                         |
| A correto / C50_full errado               | 69                                     |
| A errado / C50_full correto               | 101                                    |
| Pares discordantes                        | 170                                    |
| Bootstrap por paciente: accuracy          | diff = 0,0219; IC95% [-0,0357; 0,0812] |
| Bootstrap por paciente: balanced accuracy | diff = 0,0618; IC95% [-0,0005; 0,1230] |
| Bootstrap por paciente: F1 macro          | diff = 0,0411; IC95% [-0,0295; 0,1105] |
| Bootstrap por paciente: AUC               | diff = 0,0325; IC95% [-0,0125; 0,1211] |

Fonte: elaborado pelo autor com base nos testes estatísticos do conjunto de teste.

O McNemar por imagem indicou diferença significativa a 5%, com mais casos em que C50\_full acertou e A errou do que o contrário, dentro do caráter exploratório dessa comparação pós-seleção. No bootstrap por paciente, os efeitos médios foram positivos para todas as métricas, mas os intervalos de confiança cruzaram ou quase cruzaram zero. A balanced accuracy foi o caso mais próximo de significância. A interpretação adequada é que há evidência quantitativa favorável e promissora, porém com cautela estatística no nível do paciente devido ao tamanho reduzido do teste.

#### 4.6 Avaliação gerativa

A avaliação gerativa foi conduzida de forma amostrada, com semente 42. O FID global foi calculado apenas nos subtipos com imagens sintéticas geradas, usando limite máximo de 300 imagens por subtipo para FID e até 100 pares por subtipo para SSIM, LPIPS e PSNR. O subtipo ductal\_carcinoma não recebeu

imagens sintéticas por ser a classe majoritária usada como alvo de equalização.

**Tabela 8 - Métricas gerativas por subtipo**

| Subtipo             | FID      | SSIM   | LPIPS  | PSNR   | Reais | Sintéticas |
|---------------------|----------|--------|--------|--------|-------|------------|
| adenosis            | 284,7316 | 0,1820 | 0,8421 | 8,5844 | 253   | 1.900      |
| fibroadenoma        | 235,7016 | 0,1341 | 0,8399 | 8,2475 | 758   | 1.395      |
| phyllodes_tumor     | 308,5863 | 0,1251 | 0,8216 | 7,7415 | 60    | 2.093      |
| tubular_adenoma     | 257,8646 | 0,1095 | 0,8070 | 8,2711 | 372   | 1.781      |
| lobular_carcinoma   | 230,1126 | 0,1557 | 0,7789 | 9,0130 | 400   | 1.753      |
| mucinous_carcinoma  | 259,4122 | 0,1179 | 0,7957 | 7,6713 | 528   | 1.625      |
| papillary_carcinoma | 247,6999 | 0,1439 | 0,7801 | 8,4586 | 368   | 1.785      |

Fonte: elaborado pelo autor com base na avaliação gerativa amostrada; as colunas Reais e Sintéticas indicam as contagens disponíveis por subtipo, não necessariamente o número integral de imagens usado em cada métrica.

O FID global amostrado foi 219,668. Os valores de SSIM foram baixos e os valores de LPIPS foram altos, indicando distância relevante entre os domínios real e sintético. Portanto, as imagens geradas não devem ser apresentadas como substitutas da distribuição real. O resultado downstream positivo deve ser interpretado como efeito de augmentação controlada, não como evidência de realismo histopatológico completo.

#### 4.7 Síntese dos resultados

Os resultados sustentam três conclusões. Primeiro, a classificação em oito subtipos não confirmou a hipótese original e mostrou-se instável sob split por paciente. Segundo, a classificação binária produziu um endpoint mais estável, no qual C25 e C50\_full calibrado superaram os cenários A, B e C100 em métricas-chave. Terceiro, a qualidade gerativa foi limitada segundo FID, SSIM, LPIPS e PSNR, mas isso não impediu que as sintéticas atuassem como augmentação útil em proporção controlada.

## 5 DISCUSSÃO

A hipótese original deste trabalho previa que o sistema Encoder-Difusor superaria o baseline sem aumento e o aumento clássico, tanto em qualidade sintética quanto em desempenho downstream. Os resultados obtidos exigem uma formulação mais precisa: a hipótese foi parcialmente confirmada e refinada. O método não validou plenamente o cenário de oito subtipos e não produziu alta fidelidade gerativa segundo as métricas quantitativas. Entretanto, melhorou o desempenho downstream binário quando as imagens sintéticas foram usadas em proporção controlada.

O resultado negativo em oito subtipos é metodologicamente relevante. Ele mostra que avaliações histopatológicas não devem ser avaliadas apenas pelo número de imagens, mas pela quantidade de pacientes independentes por classe. A base BreakHis possui milhares de imagens, mas poucas unidades independentes em alguns subtipos. Ao preservar o split patient-wise, este trabalho evita vazamento, mas expõe a fragilidade estatística de classes raras. Essa exposição é uma contribuição importante, pois impede uma narrativa artificialmente otimista.

O ganho no protocolo binário mostra que o desempenho do pipeline era adequado à formulação binária. Ao contrário, quando a tarefa foi formulada em um nível diagnóstico mais estável, o classificador respondeu às imagens sintéticas. O C50\_full calibrado foi o melhor resultado completo em acurácia, balanced accuracy e F1 macro. O C25, por sua vez, alcançou a melhor AUC completa. Esses achados sugerem que a proporção sintética é uma variável crítica: o benefício não cresce monotonicamente com o volume de imagens geradas.

A comparação entre C100 e as variantes C25/C50\_full é uma das evidências mais importantes do estudo. Se dados sintéticos fossem simplesmente equivalentes a dados reais, esperar-se-ia que a equalização completa fosse superior. Isso não ocorreu. A interpretação mais consistente é que as sintéticas

ajudam como perturbações estruturadas, mas podem deslocar a distribuição de treino quando usadas em excesso. Essa leitura preserva a honestidade científica do trabalho e se alinha à visão de que sintéticos médicos devem complementar, e não substituir, dados reais (SAGERS et al., 2023).

A qualidade gerativa limitada também precisa ser tratada como resultado, não como aspecto secundário. O FID global de 219,668, combinado a SSIM baixo e LPIPS alto, indica que as imagens sintéticas se afastam da distribuição visual real. A ausência de avaliação por patologista impede afirmar plausibilidade histológica plena. Assim, o valor do método está no impacto downstream mensurado, e não na produção de imagens sintéticas visualmente perfeitas. A literatura em patologia digital recomenda justamente uma avaliação multifacetada, combinando métricas, utilidade downstream e validação especializada (POZZI et al., 2024).

A análise estatística reforça a cautela. O McNemar por imagem foi significativo em análise exploratória, mas o bootstrap por paciente foi conservador. Como há apenas 17 pacientes no teste, os intervalos de confiança por paciente são largos. A conclusão adequada é favorável, mas não definitiva: o C50\_full calibrado apresenta evidência promissora de ganho, que deve ser confirmada em bases maiores, preferencialmente externas.

O trabalho também possui limitações claras. O VAE não foi fine-tunado no domínio histopatológico por restrição de hardware, o que pode ter limitado a qualidade das imagens geradas. Não houve baseline GAN implementado no mesmo protocolo, de modo que a comparação com GANs permanece bibliográfica. Não houve avaliação qualitativa por patologista. O cenário de oito subtipos mostrou-se inviável como endpoint principal sob split por paciente. As métricas gerativas foram desfavoráveis. Por fim, o conjunto de teste possui apenas 17 pacientes, restringindo a força estatística das conclusões no nível do paciente.

Apesar dessas limitações, a contribuição permanece promissora. O estudo implementa um pipeline completo Encoder-Difusor, adota split rigoroso por paciente, documenta a falha do endpoint multiclasse, propõe uma rota binária defensável, testa proporções sintéticas, aplica calibração de threshold e realiza análise estatística. A hipótese não foi abandonada; foi refinada para uma forma mais realista e sustentada pelos dados.

## 6 CONCLUSÃO

Este TCC desenvolveu e avaliou um sistema híbrido baseado em Encoder e Difusor para aumento de dados em imagens histopatológicas de câncer de mama do BreakHis. O sistema utilizou um VAE pré-treinado como codificador latente e um LDM condicionado por subtipo histológico para geração sintética. A avaliação downstream foi conduzida com split estratificado por paciente, evitando sobreposição de pacientes entre treino, validação e teste.

A hipótese inicial previa superioridade ampla do sistema proposto sobre o baseline e o aumento clássico. Os resultados mostraram que essa hipótese precisava ser refinada. No cenário de oito subtipos, a hipótese não foi confirmada: o baixo número de pacientes em classes raras tornou a tarefa instável e levou a baixo F1 macro. Esse resultado reforça a importância de protocolos patient-wise e métricas balanceadas em histopatologia.

Na classificação binária benigno versus maligno, a hipótese foi parcialmente confirmada. O C50\_full calibrado alcançou 88,02% de acurácia, 86,73% de balanced accuracy, 86,46% de F1 macro e 92,22% de AUC, sendo o melhor experimento completo nas métricas de decisão. O C25 obteve a maior AUC completa, com 94,05%. Na análise estatística exploratória, o teste de McNemar por imagem indicou diferença significativa entre o baseline e o C50\_full calibrado, enquanto o bootstrap por paciente apresentou efeitos positivos, porém conservadores.

A avaliação gerativa apontou limitações importantes. O FID global de 219,668, associado a SSIM baixo e LPIPS alto, indica que as imagens sintéticas não substituem a distribuição visual real. Ainda assim, os ganhos downstream em C25 e C50\_full calibrado mostram que sintéticas por LDM podem ser úteis como augmentação controlada. Portanto, o valor do método está menos na fidelidade visual absoluta e mais na capacidade de melhorar a generalização do classificador quando a proporção sintética é ajustada.

Conclui-se que o sistema Encoder-Difusor é uma abordagem promissora para aumento de dados em classificação binária de histopatologia mamária, desde que avaliado com rigor e usado em proporção controlada. O trabalho contribui com um pipeline implementado, uma análise honesta da limitação dos oito subtipos, uma avaliação downstream completa, testes estatísticos e uma discussão crítica sobre qualidade gerativa. Trabalhos futuros devem incluir fine-tuning do VAE, validação externa, avaliação por patologistas, comparação experimental direta com GANs e estratégias de filtragem ou seleção das imagens sintéticas.

## REFERÊNCIAS

- ABDUSALOMOV, A.; NASIMOV, R.; NASIMOVA, N.; MUMINOV, B.; WHANGBO, T. Evaluating synthetic medical images using artificial intelligence with the GAN algorithm. \*Sensors (Basel, Switzerland)\*, v. 23, 2023. Disponível em: <https://consensus.app/papers/evaluating-synthetic-medical-images-using-artificial-abdusalomov-nasimov/e03f0bbca60e5decae68657b60333246/>. Acesso em: 19 jul. 2026.
- GOODFELLOW, I.; POUGET-ABADIE, J.; MIRZA, M.; XU, B.; WARDE-FARLEY, D.; OZAIR, S.; COURVILLE, A.; BENGIO, Y. Generative adversarial nets. In: \*Advances in Neural Information Processing Systems\*. 2014. p. 2672-2680. Disponível em: <https://consensus.app/papers/generative-adversarial-nets->



goodfellow-pouget-abadie/06b2252aaca756d8b297e8430070f1a0/. Acesso em: 19 jul. 2026.

HAQ, I.; GONG, Z.; LIANG, H.; ZHANG, W.; KHAN, R.; GU, L.; EILS, R.; KANG, Y.; HUANG, B. A review of breast cancer histopathology image analysis with deep learning: challenges, innovations, and clinical integration. *\*Image and Vision Computing\**, v. 162, artigo 105708, 2025. Disponível em: <https://consensus.app/papers/a-review-of-breast-cancer-histopathology-image-analysis-haq-gong/17d2387f309c5fec829b60f26d8ddca7/>. Acesso em: 19 jul. 2026.

HO, J.; JAIN, A.; ABBEEL, P. Denoising diffusion probabilistic models. *\*arXiv\**, abs/2006.11239, 2020. Disponível em: <https://consensus.app/papers/denoising-diffusion-probabilistic-models-ho-jain/0ad4daebe8b25762983457d675e2086d/>. Acesso em: 19 jul. 2026.

KAZEROUNI, A.; AGHDAM, E. K.; HEIDARI, M.; AZAD, R.; HACIHALILOGLU, I.; MERHOF, D. Diffusion models in medical imaging: a comprehensive survey. *\*Medical Image Analysis\**, v. 88, artigo 102846, 2022. Disponível em: <https://consensus.app/papers/diffusion-models-in-medical-imaging-a-comprehensive-kazerouni-aghdam/eb1b270b9c3f5b8a902ab6ef44145064/>. Acesso em: 19 jul. 2026.

KEBAILI, A.; LAPUYADE-LAHORGUE, J.; RUAN, S. Deep learning approaches for data augmentation in medical imaging: a review. *\*Journal of Imaging\**, v. 9, 2023. Disponível em: <https://consensus.app/papers/deep-learning-approaches-for-data-augmentation-in-medical-kebaili-lapuyade-lahorgue/4319b8d4f33556658086ae1a2352fa6a/>. Acesso em: 19 jul. 2026.

MÜLLER-FRANZES, G.; NIEHUES, J.; KHADER, F.;  
TAYEBI ARASTEH, S.; HAARBURGER, C.; KUHL, C.;  
WANG, T.; HAN, T.; NEBELUNG, S.; KATHER, J. N.;  
TRUHN, D. A multimodal comparison of latent denoising  
diffusion probabilistic models and generative adversarial  
networks for medical image synthesis. \*Scientific  
Reports\*, v. 13, 2022. Disponível em:  
[https://consensus.app/papers/a-multimodal-comparison-of-  
latent-denoising-diffusion-müller-franzes-  
niehues/0ad159d141ed5945a96359303504a980/](https://consensus.app/papers/a-multimodal-comparison-of-latent-denoising-diffusion-müller-franzes-niehues/0ad159d141ed5945a96359303504a980/). Acesso  
em: 19 jul. 2026.

OSÓRIO, P.; JIMÉNEZ-PÉREZ, G.; MONTALT-TORDERA,  
J.; HOOGE, J.; BALLESTER, G. D.; SINGH, S.;  
RADBRUCH, M.; BACH, U.; SCHROEDER, S.;  
SIUDAK, K.; VIENENKOETTER, J.; LAWRENZ, B.;  
MOHAMMADI, S. Latent diffusion models with image-  
derived annotations for enhanced AI-assisted cancer  
diagnosis in histopathology. \*Diagnostics\*, v. 14, 2023.  
Disponível em: [https://consensus.app/papers/latent-  
diffusion-models-with-image-derived-annotations-osorio-  
jimenez-prez/e442790a1772529c9fab8364561f622a/](https://consensus.app/papers/latent-diffusion-models-with-image-derived-annotations-osorio-jimenez-prez/e442790a1772529c9fab8364561f622a/).  
Acesso em: 19 jul. 2026.

POZZI, M.; NOEI, S.; ROBBI, E.; CIMA, L.; MORONI, M.;  
MUNARI, E.; TORRESANI, E.; JURMAN, G.  
Generating and evaluating synthetic data in digital  
pathology through diffusion models. \*Scientific Reports\*,  
v. 14, 2024. Disponível em:  
[https://consensus.app/papers/generating-and-evaluating-  
synthetic-data-in-digital-pozzi-  
noei/2b3ab42072185c34bff6c6b5f572e891/](https://consensus.app/papers/generating-and-evaluating-synthetic-data-in-digital-pozzi-noei/2b3ab42072185c34bff6c6b5f572e891/). Acesso em:  
19 jul. 2026.

PRIYANKA, V.; NARENDRA, M.; RAO, T. D. A patient-aware  
benchmarking of CNN and transformer architectures for  
breast cancer histopathology classification. \*Frontiers in  
Digital Health\*, v. 8, 2026. Disponível em:  
<https://consensus.app/papers/a-patientaware->

benchmarking-of-cnn-and-transformer-priyanka-narendra/e86c2e160df557e8854909d5a9ba54ca/. Acesso em: 19 jul. 2026.

ROMBACH, R.; BLATTMANN, A.; LORENZ, D.; ESSER, P.; OMMER, B. High-resolution image synthesis with latent diffusion models. In: \*IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)\*. 2022. p. 10674-10685. Disponível em: <https://consensus.app/papers/highresolution-image-synthesis-with-latent-diffusion-rombach-blattmann/03b35de953ad5578bf16d607f03220f6/>. Acesso em: 19 jul. 2026.

SAGERS, L.; DIAO, J. A.; MELAS-KYRIAZI, L.; GROH, M.; RAJPURKAR, P.; ADAMSON, A.; ROTEMBERG, V.; DANESHJOU, R.; MANRAI, A. Augmenting medical image classifiers with synthetic data from latent diffusion models. \*arXiv\*, abs/2308.12453, 2023. Disponível em: <https://consensus.app/papers/augmenting-medical-image-classifiers-with-synthetic-data-sagers-diao/18629e8691cc5631a9fccfd2809d3b63/>. Acesso em: 19 jul. 2026.

SONG, J.; MENG, C.; ERMON, S. Denoising diffusion implicit models. \*arXiv\*, abs/2010.02502, 2020. Disponível em: <https://consensus.app/papers/denoising-diffusion-implicit-models-song-meng/147ff3111d6352e9bc9e2ce9d9636d3a/>. Acesso em: 19 jul. 2026.

SPANHOL, F.; OLIVEIRA, L.; PETITJEAN, C.; HEUTTE, L. A dataset for breast cancer histopathological image classification. \*IEEE Transactions on Biomedical Engineering\*, v. 63, p. 1455-1462, 2016. Disponível em: <https://consensus.app/papers/a-dataset-for-breast-cancer-histopathological-image-spanhol-oliveira/5d7ad89670be55599be9d1d2b2da22aa/>. Acesso em: 19 jul. 2026.

TAN, M.; LE, Q. V. EfficientNet: rethinking model scaling for convolutional neural networks. \*arXiv\*, abs/1905.11946, 2019. Disponível em: <https://consensus.app/papers/efficientnet-rethinking-model-scaling-for-convolutional-tan-le/d6b4b40fcce5610bb5073d87b622bab/>. Acesso em: 19 jul. 2026.